01 / 문제와 제안

KitGuard · 소량 키트의 수량과 근거를 함께 검증하는 로컬 Agent

팀: 해피 / 국립창원대학교 인공지능융합공학과
작성 기준: 2026-09-26 / 개발 진행 중 / 정식 제출본 아님

현재 결론: 주문·사진·보완·완료의 일관성을 지키는 소프트웨어 흐름은 구현했습니다. 그러나 실제 현장 인식 정확도나 작업 시간 개선은 아직 입증하지 못했습니다. 본 문서는 불리한 개발 결과와 미검증 항목도 함께 남기는 결과보고서 초안입니다.

해결하려는 상황

소량 키트는 단순해 보여도 누락·초과, 주문 수량 변경, 예전 사진의 재사용 때문에 확인 근거가 어긋날 수 있습니다. KitGuard는 사진에서 관찰한 수량과 현재 주문을 분리해 비교하고, 부족한 근거에는 다음 행동을 요청합니다. 수량이 맞아도 사람이 실물을 확인해야 완료됩니다.

주문·참조 – 사진 관찰 – 규칙 비교 – 보완·재검사 – 사람 확인

현재 제품 범위

포함	제외 또는 미검증
볼트·너트·와셔·브래킷 4분류 항목별 0-3개, 합계 1-12개	나사 길이·재질·나사산·SKU 구분 복잡한 조립 상태와 안전 인증
사진과 선택적 단품 참조, 수량 수정 제안 한·중 UI, 한·중·영 수량 변경 문장	실제 공장 도입 성과·불량 비용 절감 지원 범위를 넘는 장면의 자동 처리
Mac 로컬 처리, 단일 작업자 프로토타입	Windows·RTX 3080/CUDA 실측 다중 사용자 운영·공개 서버 배포

차별화의 정확한 범위

개별 이미지의 검출 성능을 새로 발명했다고 주장하지 않습니다. 팀의 구현 초점은 주문 버전·참조·사진·검증 결과를 묶고, 이전 요청과 새 관찰을 비교하여 보완 흐름을 유지하는 데 있습니다. 이 설계가 실제 오류와 시간을 줄이는지는 별도 대조 실험으로 확인해야 합니다.

02 / 실제 구현과 Agent 흐름

단계	실행과 기록
1. 요구 확인	구조화 수량을 저장합니다. 자연어 변경은 승인 전 제안이며 주문을 직접 바꾸지 않습니다.
2. 사진 관찰	로컬 VLM에 사진과 선택적 단품 참조를 전달합니다. 사진 관찰 입력에는 목표 수량을 넣지 않습니다. 불명확한 수량은 null입니다.
3. 규칙 비교	서버가 관찰값과 현재 요구량의 차이를 계산합니다. 출력 형식 오류, 모델 실패, 시간 초과는 성공으로 처리하지 않습니다.
4. 다음 행동	불확실하면 분리·재촬영·수동 확인, 명확한 수량 차이는 추가/제거를 안내합니다. 관찰값을 주문 상한에 억지로 맞추지 않습니다.
5. 새 근거 검토	이전 행동 종류·불명확 분류·영역만 주의 정보로 전달합니다. 이전 수량과 목표/증감 문구는 제외하며 새 사진에서 다시 셉니다.
6. 확인·저장	최신 유효 ready와 명시적 사람 확인이 있어야 완료 기록을 만듭니다. 이력에는 요구·사진·관찰·차이·모델·실행 단계가 남습니다.

상태와 근거의 보호

새 사진, 참조 변경, 주문 개정은 이전 ready를 무효화합니다. 추론 시작 때의 revision과 evidence_epoch를 종료 시 다시 확인하므로 오래된 추론 결과가 새 상태를 덮어쓸 수 없습니다. 완료 요청은 트랜잭션과 멱등 키로 처리하며, 완료 후 개정해도 과거 확인 기록은 보존됩니다.

보완 예산은 같은 버전·참조의 연속 불명확 구간만 셉니다. 같은 저장 사진 재검사는 새 증거가 아니며, 서로 다른 사진 두 번의 보완 후에도 불명확하면 수동 확인으로 전환합니다. 명확한 판단이나 버전·참조 변경은 구간을 재설정합니다. 사진 ID 규칙은 실제 촬영 진위나 중복 재업로드를 인증하지 않습니다.

모델과 도구

현재 기준 모델은 Qwen3-VL-8B-Instruct의 MLX 8-bit 공개 양자화본입니다. 27B 후보는 Qwen3.6-27B의 MLX 4-bit이며 현재 상태는 파일 다운로드·검증 중, 실측 대기입니다. 모델 선택은 메모리·시간·출력 오류와 개발 성능을 함께 비교한 뒤 확정합니다.

구성: FastAPI / SQLite / MLX-VLM / HTML·CSS·JavaScript. 증거 ZIP은 당시 사진·참조·개정·관찰·확인 및 SHA-256과 오프라인 뷰어를 담는 읽기 전용 스냅샷입니다.

03 / 보존된 개발 결과와 해석

아래 세 실행은 원본 PNG를 관찰기에 직접 넣은 초기 탐색입니다(관찰기 내부 크기 처리는 적용). 완료된 run.json·predictions.jsonl에서 읽으며 같은 개발 사진을 반복 사용했습니다. 최종 비교는 실제 업로드의 JPEG 정규화를 거치는 app-upload 경로를 사용합니다. 두 입력 경로의 차이를 모델 개선 효과로 해석하지 않습니다.

개발 실행	사진	4분류 전부 정답	명확한 관찰	그중 계수 오답	중위 시간
Screws 8B v1	16	1/16	0/16	분모 없음	5.46초
Screws 8B v2	16	3/16	16/16	13/16	3.12초
LOCO 8B v1	16	9/16	16/16	7/16	3.03초

명확한 관찰: 네 수량이 모두 non-null, issues가 비어 있고 action.kind=none인 출력입니다. 이는 맞는 관찰 또는 주문 ready를 의미하지 않습니다. 0/0은 오류율 0%가 아니라 분모 없음입니다. 시간은 실제 observe 경로의 단일 사례 벽시계 시간으로, 해당 실행의 초기 로딩 비용을 포함합니다.

Screws 결과가 말해 주는 것

v1의 1/16에서 v2의 3/16으로 전체 계수가 맞은 사진은 늘었지만, v2의 명확한 관찰 16개 중 13개는 계수가 틀렸습니다. 명확한 출력 증가 자체는 신뢰도 개선이 아닙니다. 이 16장은 모두 항목별 3개 상한을 넘어 제품 범위의 주문 평가 분모가 0입니다. 실제 오출고율 또는 제품 주문 성공률로 바꿔 부를 수 없습니다.

LOCO 결과의 별도 범위

LOCO screw_bag의 정상 구성은 볼트 2·너트 2·와셔 2·브래킷 0으로 고정됩니다. 정상과 단일 수량 결함을 나누어 보고해야 하며, 상수 2/2/2/0 추측도 정상 사례에는 맞습니다. 길이가 다른 나사를 bolt로 합쳐 같은 총수의 규격 대체 오류를 놓칠 수 있고, 브래킷 양성 사례도 없습니다.

LOCO 원본 상태: 전체 원본 압축본 SHA 검증 대기. 파일 해시 일치와 전체 원본 패키지 검증을 구분합니다. 개발용으로 재배정한 공식 test 일부가 있으므로 untouched official test 성적이라고 부르지 않습니다.

최종 확정 대기

항목	현재 상태
27B 동일 입력 비교 / 최종 모델	파일 다운로드·검증 중, 실측 대기
동결 후 보류 표본 평가	아직 최종 결과로 채택하지 않음. 실행 완료·전체 실패 기록·분모 확인 필요
사람 기준선 / 연속 실물 보완 효과	미측정. 작업 시간 단축·누락 감소 수치 없음

04 / 재현 가능한 대조와 검증 계획

정적 이미지 대조

실행 전에 원본 사진·진실값 매핑·분할·SHA-256·평가 단위를 manifest로 동결합니다. 공개 원본 전체 사진을 사용하고, 자르기·합성·생성 이미지를 실물 보완으로 제시하지 않습니다. 모델과 프롬프트 비교는 같은 선정 이미지와 규칙을 사용하며, 참조 변경·해상도 변경은 별도 실행으로 남깁니다.

완전 계수는 네 분류가 모두 맞아야 통과합니다. 거절·실행 오류·시간 초과도 선정 사진 분모에서 제외하지 않습니다. 명확한 관찰 비율과 그 안의 오답을 함께 보고합니다. 동일 사진에서 파생한 주문들은 추가 독립 사진이 아닙니다. 하나의 고정 수량 교란만으로 모든 불일치 주문을 대표할 수 없습니다.

실물 현장 대조 - 아직 실행 전

비교 조건	동일하게 유지할 것	따로 기록할 비용·효과
사람 체크리스트	시작 부품 구성·현재 요구·검수 기준	총 시간, 완료 후 실제 누락·초과
한 번의 VLM 관찰 + 사람 확인	같은 종류의 시작 구성, 관찰 범위	오답·잘못된 ready·사람 수정·시간
KitGuard 보완 흐름 + 사람 확인	같은 종류의 시작 구성, 동일 완료 기준	추가 사진 수·수동 전환·최종 오류·총 시간

시나리오와 순서는 결과를 보기 전에 정하고, 참가자 간 순서를 교차 배치합니다. 시작 진실값과 완료 후 진실값을 사람의 별도 실물 점검으로 기록합니다. 연구 참가자 수·실물 사진 수는 아직 확정 실적이 아니므로 이 초안에 성과 숫자로 넣지 않습니다.

검증 가능한 제품 수용 조건

상태 보호: 사진·참조·버전 변경 뒤 오래된 결과로 완료되는 사례가 없어야 합니다. 실행 실패·잘린 출력·추론 취소도 완료로 기록되면 안 됩니다. 이 조건은 자동화된 임시 데이터 테스트로 검사합니다.

유효성: 실제 사진에서 요구한 다음 행동과 이후 관찰의 관계를 재생 가능하게 보여 주어야 합니다. 전후 사진만으로 동일 부품을 실제 이동했다는 사실을 단정하지 않습니다. 사용자 효용: 사람 기준선과 비교한 오류·시간·개입 비용을 함께 확보한 후 개선 주장을 정합니다. 임의의 정확도 목표 달성으로 수용 결론을 대신하지 않습니다.

공학 테스트의 합성 이미지·가짜 관찰기는 상태·API·UI 검증용입니다. 통과한 테스트 개수는 실제 인식 표본 수나 산업 안전 증거가 아닙니다.

05 / 배포·재현·출처와 개발 고지

현재 실행과 재현

본기기 검증은 Apple Silicon Mac의 MLX 경로입니다. 사용자 제공 사양은 M5 Pro·64 GB입니다. 데스크톱 i9-9900KF·RTX 3080 10 GB·RAM 32 GB를 보유했지만 이 문서는 Windows/CUDA 실행 성과를 주장하지 않습니다. 사진 추론은 로컬이며 외부 LLM API로 사진을 보내지 않습니다.

절차	프로젝트 루트에서 실행 / 확인
환경	bash scripts/setup.sh requirements-lock.txt로 의존성 확인
기준 모델	.venv/bin/python scripts/download_model.py 공유 디렉터리와 manifest·라이선스 확인
27B 후보	.venv/bin/python scripts/download_candidate_model.py KITGUARD_MODEL_PATH / KITGUARD_MODEL_PROFILE로 선택
기동	bash scripts/run.sh http://127.0.0.1:8765 (단일 프로세스)
검증	.venv/bin/python -m pytest -q .venv/bin/ruff check kitguard tests scripts
백업·평가	서비스 종료 후 data/ 전체 복사 scripts/run_benchmark.py, run_instruction_benchmark.py의 --help 확인

다운로드에는 네트워크가 필요합니다. 로컬 모델 파일 준비, 실제 로딩 성공, 과제 성능은 별개입니다. GPU 추론은 한 작업 스레드에서 직렬 실행합니다. HTTP 시간 초과 뒤에도 하위 추론이 남을 수 있어 오래 멈추면 서비스를 재시작합니다.

AI 코드 사용과 팀 개발 범위

Codex가 공개 자료 조사, 앱·상태관리·보완 피드백·UI·테스트·평가 도구와 문서 초안의 생성·수정에 참여했습니다. 공개 Qwen/MLX 모델을 이용하며 가중치를 자체 학습했다고 주장하지 않습니다. 테스트와 문서 생성에는 Pillow·ReportLab 등 공개 도구를 사용했습니다. 팀은 제출 전 실행·출처·수치·라이선스와 AI 사용 고지를 최종 검토해야 합니다.

실제 개발 날짜와 참가 자격 미결

실제 개발 시작은 2026-09-26입니다. r1 최종 신청서의 참가자 동의서에는 “개발기간 외 사전 개발, 타인 작품 도용, 부문 교차 구성 등의 부정행위를 하지 않겠습니다.”라는 조항이 있습니다. 공개 모델·AI 도구 허용을 사전 개발 코드 허용으로 해석하지 않습니다. 본 사전 프로토타입의 대회 사용 적격성은 주최 측 확인이 필요하며, 이 초안은 제출 또는 승인된 문서가 아닙니다.

대회 공식 규정 · Qwen 모델카드 · MVTec 공개 데이터

로컬 근거: docs/INDEPENDENT_REVIEW.md, docs/DATA_PROVENANCE.md, evaluation-runs/*/run.json. Qwen 모델은 Apache-2.0, Screws·LOCO 데이터는 CC BY-NC-SA 4.0으로 출처와 이용 조건을 보존합니다.